### Folgend: Interessante NLP-Packages

Montag, 30. März 2020 18:1

Praktische Beispiele sind immer in den einzelnen Abschnitten:

koRpus: Bekommen von Statistiken zu Wordcounts, etc. Readability, lexical.diversity

wordcloud: Visualisieren von Wörtern Anhand ihrer Häufigkeit

<u>hunspell - High Performance Stemmer</u>: Checkt Rechtschreibung, parsed text, schlägt richtige Wörter vor, sucht Wortstamm von Wörtern

14:39

koRpus (https://cran.r-project.org/web/packages/koRpus/index.html)

- Für Infos zum richtigen installieren: <a href="https://reaktanz.de/?c=hacking&s=koRpus">https://reaktanz.de/?c=hacking&s=koRpus</a>
- Doku: <a href="https://reaktanz.de/R/pckg/koRpus/koRpus.pdf">https://reaktanz.de/R/pckg/koRpus/koRpus.pdf</a>
- Benötigt für vieles: TreeTagger <a href="https://www.cis.uni-muenchen.de/">https://www.cis.uni-muenchen.de/</a> ~schmid/tools/TreeTagger/
- Problem: Schaut recht kompliziert aus, hinsichtlich des Formates, was die Daten haben müssen
  - Kann sehr aufwendig sein, bis wir uns da reingearbeitet haben, wie das richtig funktioniert!
- Vorteil: die Readability-Packages sehen sehr m\u00e4chtig aus siehe z.B. Doku Seite 45
- ➤ Interessante Funktionen
  - lexical diversity-Funktionen: wie oft werden Wörter wiederholt, etc.
    - -> für bessere Beschreibung: https://textinspector.com/help/lexical-diversity/
    - -> gibt einen Haufen Indexe, da müssten wir uns noch näher reinlesen!
      - lex.div

```
C characteristics:
  Min. 1st Qu. Median
                        Mean 3rd Qu.
                                        мах.
 0.8255 0.8733 0.8857 0.8952 0.9279 1.0000
  SD
0.0404
Guiraud's R
  R: 5.2
R characteristics:
  Min. 1st Qu. Median Mean 3rd Qu.
                                        Max.
 2.236
        5.138 5.391 5.127 5.683
                                       6.155
  SD
0.9539
carroll's CTTR
  CTTR: 3.68
CTTR characteristics:
  Min. 1st Qu. Median Mean 3rd Qu.
                                        Max.
       3.633 3.812 3.625 4.019
 1.581
                                       4.352
  SD
0.6745
Uber Index
```

- Readability-Funktionen z.B. Komplexität der Sätze/Wörter, Reading Ease, etc.
  - -> müssten wir uns auch reinlesen
    - readability

```
.ene languaget en
                   index
                            flavour raw grade
                                                 age
1
                    ARI
                                           10.7
                                       72 3.29
2
            Coleman-Liau
                                     7.29
     Danielson-Bryan DB1
3
    Danielson-Bryan DB2
                                            7-8
4
                                    52.13
5
          Dickes-Steiwer
                                    63.19
6
                     ELF
                                      2.8
7
  Farr-Jenkins-Paterson
                                      81.8
                                              6
8
                  Flesch en (Flesch) 81.67
                                              6
9
                                           9.87 14.9
          Flesch-Kincaid
10
                                          13.13
11
                 FORCAST
                                            6.3 11.3
                  Fucks
                                    109.6 10.47
12
                                           16.3
13
           Linsear-Write
                                    38.41
14
                    LIX
                                              6
15
                    nWS1
                                           2.45
16
                    nWS2
                                           3.61
17
                    nWS3
                                            5.2
18
                    nWS4
                                           7.03
19
                    RIX
                                             6
20
                    SMOG
                                            5.68 10.7
                                    10.56
21
                  Strain
22
                                     2.25
                    TRI
23
                 Tuldava
                                      3.8
           Wheeler-Smith
                                              4
24
                                       28
```

- flesch
- flesch kincaid
- forcast
- guess\_lang -> Funktion, was die Sprache erkennt
- > freq.analysis

```
freq
sentences
                    5.000000
avg.sentence.length 32.200000
                  161.000000
avg.word.length
                   3.403727
all.characters
                 762.000000
letters
                  548.000000
lemmata
                   1.000000
questions
                    5.000000
                   0.000000
exclamations
                   0.000000
semicolon
colon
                    0.000000
```

> textFeatures

> textFeatures(test2)

uniqwd complx sntCt sntLen syllCt charCt lttrCt FOG flesch 69 0.4099379 5 32.2 1.093168 762 548 13.12845 81.67001

treeTag - damit werden Daten vorbereitet

#### Interessante Funktionen:

wordcloud - visualisiert Wörter Anhand ihrer Häufigkeit



#### hunspell - High Performance Stemmer

Montag, 30. März 2020 18:44

"Who" "kind" "me"

'what"

me "girl" "she" "I'm" "do"

could'

me "how" "she" "could"

"blue" "what" "' "

stem(unlist(hunspell
"at" "h"
"to" "me"
"me" "how"

me"
st(huns,
"look"
j "special"
j "special"
j "see"
49] "that"
(61] "h"
[73] "T"

```
Interessante Funktionen:
   hunspell(text) - testet auf Rechtschreibfehler im Englischen und gibt Fehler zurück
               > test$song[1]
[1] "Ahe's My Kind of Girl"
> hunspell(test$song[1], format = "text")
               > hune,
[[1]]
[1] "Ahe's"
   hunspell parse(text) - entfernt Satzzeichen
                > hunspell_parse(test$text[1])
                [[1]]
[1]
[13]
                        "Look"
"special'
"sees"
"of"
"she"
"I'm"
                                                                                                            "it's"
"at"
"can"
"me"
                                                                                                                                 "a"
"the"
"one"
"feel"
                                                                                        "face"
"Look"
"lucky"
"makes"
                                                                                                                                                      "wonderful"
                                                                                                                                                                                                "And"
"she"
"She's"
                                                                   "her"
"me"
                                                                                                                                                                           "face"
"that"
                                                                                                                                                                                                                                          "means"
                                                                                                                                                                                                                                                              "something"
                                               "to"
"me"
"girl"
                                                                                                                                                                                                                     "smiles"
                                                                                                                                                      "way"
"fellow"
"fine"
                                                                                                                                                                                                                                          "when'
                                                                                                                                                                                                                                                               'she'
                                                                    "How
                                                                                                                                                                           "be"
"Who"
"kind"
                                                                                                                                                                                                                     "just"
"ever"
"girl"
                                                                                                                                                                                                                                                               "kind"
                                                                                                                                                                                                                                          "my"
"believe"
                                                                    "she"
"be"
                                                                                                                                                                                                "could"
"of"
                                                                                        "makes
                                                                                                                                  "just"
"ever"
                                                'could"
                                                                                                              "She's
"she"
                  [49]
                                                                                         "mine'
"if"
                                                                                                                                                       "my"
"leaves'
                                                                                                                                                                                                                                          'without
                                                                                                                                                                                                                                                               "her
"do"
                                                                     'And"
                                                                                                                                                                                                "what"
                                                                                                                                                                            "me"
"go"
                                                                                                                                                                                                                      'could'
                  [61]
                                               "blue
                                                                                                                                                                                                                                                             "in"
"go"
"we"
"fine"
"mv"
                          "what"
"the"
"on"
                                                                    "I"
"And"
"for"
                  [73]
[85]
                                                                                        "do"
"she"
                                                                                                             "And"
"holds"
                                                                                                                                                                                                                                          "walk"
"we'll"
                                                "could"
                                                                                                                                  "when"
                                                                                                                                                      "we"
"and"
                                                                                                                                                                                                "for"
                                                                                                                                                                           "squeezes
"all"
"she"
"be"
                                                                                                                                                                                                                      hand"
                                               "park
                                                                                                                                   'me
                                                                                                                                                                                                "my"
"the"
                                                                                         "hours"
                                                                                                                                   'talking'
                                                                                                                                                                                                                                         "that"
"feel"
"just"
                                                                                                                                                       "About"
                                                'walking'
                  [97]
                                                                                                              'and'
                                                                                                                                                                                                                     "things
                                                                   Tor"
"just"
"ever"
"girl"
"could"
                [109]
[121]
[133]
                         "plan"
"Who"
"kind"
                                               "She's"
"could"
                                                                                                              "kind"
                                                                                                                                  "of"
"she"
"I'm"
                                                                                                                                                       "girl"
"could"
                                                                                                                                                                                                "makes"
"mine"
                                                                                        "my"
"believe"
                                                                                                             "that"
                                                                                                                                                                           "And"
"I"
                                                                                        "without"
                                                                                                                                                                                                                                                               'leaves
                                                of'
                                                                                                              'her'
'do"
                                                                                                                                                       "blue
                                                                                                                                                                                                "if"
"do"
                                                                                                                                                                                                                      'she'
                                                                                                                                                                                                                                          'ever
                                               "what"
                                                                                                                                                       'could"
                                                                                                                                   'what'
   hunspell_check - testet darauf ob einzelne Wörter falsch geschrieben sind
                > hunspell_parse(test$song[1])
[[1]]
[1] "Ahe's" "My" "Kind" "O
                                                  "Kind" "Of"
                [1]
                > hunspell_check(unlist(hunspell_parse(test$song[1])))
[1] FALSE TRUE TRUE TRUE TRUE
   hunspell_suggest - schlägt Wörter für falsche Wörter vor
                   unlist(hunspell_parse(test$song[1]))[!hunspell_check(unlist(hunspell_parse(test$song[1])))]
.] "Ahe's"
hunspell_suggest(unlist(hunspell_parse(test$song[1]))[!hunspell_check(unlist(hunspell_parse(test$song[1]))])
                [1]
                [[1]]
[1] "He's"
                                       "Ashe's" "She's" "Abe's" "Ave's" "Che's" "A he's" "Age's" "Ache's" "Are's" "Ale's" "Ace's" "Ape's" "Aye's" "Awe's"
      hunspell_stem - gibt Wortstamm für ein Wort aus, damit es in einer Wortwolke
       zusammengefasst werden kann (z.B. she und she's zusammenfassen) - funktioniert aber nicht
       Perfekt, siehe "her" -> "h" beim stem
                 "face"
"Look"
"lucky"
"makes"
"mine"
                                                                                                             "it's"
"at"
"can"
"me"
                                                                                                                                                                           "face"
"that"
"be"
                                                                                                                                                                                                "And"
"she"
"She's"
                                                                                                                                  "a"
"the"
"one"
"feel"
                                                                                                                                                       "wonderful"
                                                                                                                                                                                                                                          "means"
"when"
                                                                                                                                                                                                                                                               "something"
                                                                                                                                                                                                                    "it"
"smiles"
"just"
"ever"
"girl"
"sowld"
                                                                                                                                                                                                                                                              "she"
"kind"
                                                                                                                                                       "way"
"fellow
                                                                                                                                                                                                                                          'mv"
                                                                                                                                                                            'who"
                                                                                                                                                                                                                                          "believe
                                                                                                                                                                                                "could"
"of"
                                                                                                                                                                                                                                                              "that
"her"
                                                                                                                                                       "fine"
                         "of"
"she"
"I'm"
"what"
"the"
"on"
"plan"
"who"
                                                                                                                                   'just"
                                                                                                                                                                            "kind"
                                                                                                                                                                                                                                          'without
                                                                                                                                                                                                "what"
"for"
"my"
"the"
                                                                                                                                                                            "me"
"go"
"squeez
"all"
                                                                                                                                                                                                                      'could'
                                                                                                                                                        'leaves'
                                                                                         "if"
"do"
                                                                                                              "she
                                                                                                                                   'ever
                                                                                                                                                                                                                                                               'do'
                                                                                                                                                                                                                                          'walk"
                                                'could"
                                                                                                                                   "when"
                                                                                                              "And"
                                                                                                                                                       "we
                                                                                                                                                                                                                                                               'in"
                                                                                                                                                       "we"
"and"
"About"
                                                                                                                                                                                                                                         "We'll"
"that"
"feel"
"just"
"ever"
                                                "park"
"walking"
"She's"
                                                                                         "she"
"hours"
                                                                                                                                                                                                                                                              "go"
"we"
"fine"
                                                                     'And"
'for"
                                                                                                                                   "me"
"talking"
                                                                                                                                                                                                                     "hand"
"things"
                                                                                                              "holds"
                                                                                                              "and"
"kind"
                                                                                                                                                                           "she"
"be"
                                                                    "just"
"ever"
"girl"
                [109]
[121]
[133]
                                                                                                                                                       "girl"
"could"
                                                                                                                                                                                                "makes"
                                                                                         "my"
"believe'
                                                                                                                                   of"
                                                                                                             "that'
                                                                                                                                  "she"
"I'm"
                                                "could"
"of"
                                                                                                                                                                                                "mine"
                                                                                                                                                                                                                    "She's'
"she"
                                                                                                                                                                                                                                                              "my"
"leaves"
```

"what"

"a" "the" "one"

"feel" "she" "she"

"Ī" ...

without"

'do'

"at"

"can"

"me" "mine"

"if" "i" "

[1])))) "it"

"I"
"se(test\$t
"face"
"look"
"lucky"
"make"
"be"
"and"
"sould"

"could"

"blue

"could"

"way" "fellow

"fine"
"just"

'ever

"wonderful

'And"

"face" "that"

"be"

"who" "my"

'leave'

"and"

"do"

"and" "she" "she" "Who" "kind"

'me'

"when"

"mean"
"when"
"my"
"ever"
"girl"

'could"

"go"

"it" "smile" "just"

"could" "of"

"what"

"something" "she" "kind"

"believe" "without"

"for"

# tidytext

Montag, 30. März 2020 21:02

### Interessante Funktionen:

cast\_sparse - versteh ich noch nicht, was das bringt

# Nicht geeignete Packages

Montag, 30. März 2020 18:39

Package	Wieso nicht geeignet?
tau	Ungeeignete Funktionen
languageR	Zu detailierte Informationen zu Lyrik und nicht für normale Texte
zipfR	Auch zu spezifisch für Wortanalysen, nicht für texte geeignet
Mscstexta4r - R-Client für Microsoft Cognitive Services Text Analytics	Wäre super für Sentiment-Analysen, aber nur 5000 Anfragen wären gratis und wir haben deutlich mehr für alle Lieder
openNLP	Funktionen dienen eher zum summarisen von Sätzen oder zum Tokenizen - bringt uns für unsere Fragestellungen ziemlich garnix
	OpenNLP selbst dürfte extrem leistungsstark sein, aber die Packages, die bereits existieren haben für uns keine sinnvollen Funktionen